

Predicted

Negative

Neutral

Positive

# การคำนวณค่าประเมินประสิทธิภาพ สำหรับปัญหา Classification 3 คลาส

Actual

ขั้นตอนการคำนวณ Accuracy, Precision, Recall, F1-score และ AUC/ROC

Neutral

200

8300

100

✓ Accuracy

🔍 Precision

↺ Recall

📊 F1-score

~ AUC/ROC

Positive

0

100

300



# บทนำ: การประเมินประสิทธิภาพโมเดล Classification

## เมตริกการประเมินประสิทธิภาพ

- ✓ **Accuracy** - ความถูกต้องโดยรวมของโมเดล
- 🔍 **Precision** - ความแม่นยำของการทำนายคลาสบวก
- ↺ **Recall** - ความสามารถในการตรวจจับคลาสบวก
- 📊 **F1-score** - ค่าเฉลี่ยเชิงฮาร์โมนิกของ Precision และ Recall
- ✓ **AUC/ROC** - พื้นที่ใต้เส้นโค้งลักษณะการทำงานของตัวรับ

## ความสำคัญของการประเมินประสิทธิภาพ

- วัดประสิทธิภาพของโมเดลอย่างเป็นระบบ
- เปรียบเทียบโมเดลต่างๆ ได้อย่างเป็นธรรม
- ช่วยเลือกเมตริกที่เหมาะสมกับปัญหา
- สำหรับ 3 คลาส ต้องคำนวณแต่ละคลาสและรวมกัน

		Predicted		
		Negative	Neutral	Positive
Actual	Negative	700	300	0
	Neutral	200	8300	100
	Positive	0	100	300

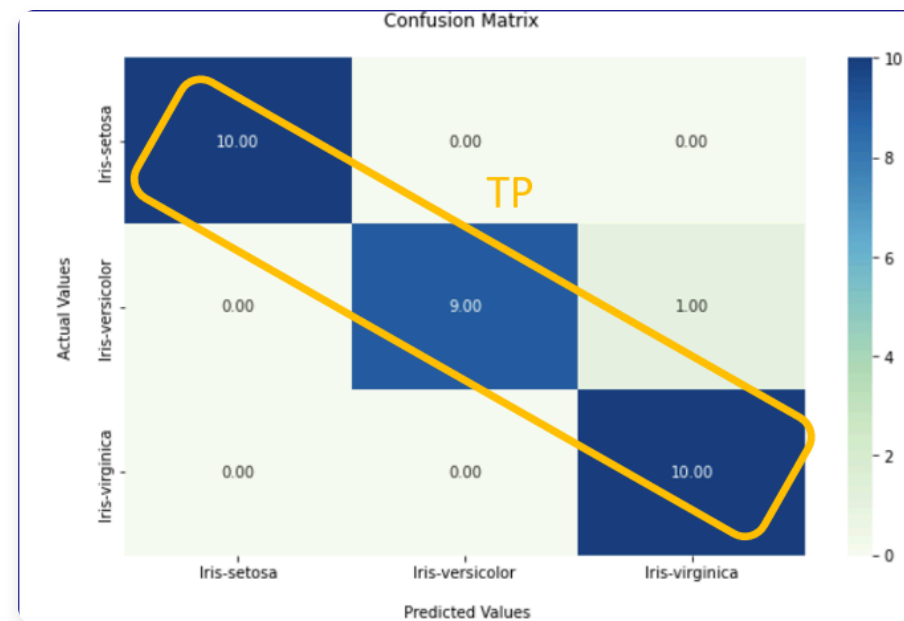
# Confusion Matrix สำหรับ 3 คลาส

## การทำความเข้าใจ Confusion Matrix

- เมทริกซ์ 3x3 ที่แสดงการทำนายเทียบกับค่าจริง
- แถว = คลาสจริง (Actual)
- คอลัมน์ = คลาสที่ทำนาย (Predicted)
- เส้นทแยงมุม = การทำนายถูกต้อง (TP)
- เป็นฐานในการคำนวณเมตริกอื่นๆ

### การคำนวณค่าต่างๆ

- TP (True Positive): ค่าบนเส้นทแยงมุม
- FP (False Positive): ผลรวมของคอลัมน์ (ยกเว้น TP)
- FN (False Negative): ผลรวมของแถว (ยกเว้น TP)
- TN (True Negative): ผลรวมของเซลล์ที่ไม่ใช่แถวหรือคอลัมน์ของคลาสนั้น



### Accuracy จาก Confusion Matrix

$$\text{Accuracy} = (\text{TP}_1 + \text{TP}_2 + \text{TP}_3) / \text{ผลรวมทั้งหมด}$$

TP

FP

FN

# การคำนวณ Accuracy สำหรับ 3 คลาส

# สูตรการคำนวณ Accuracy

## Σ สูตร Accuracy

Accuracy = (จำนวนการทำนายถูก) / (จำนวนการทำนายทั้งหมด)

$$\text{Accuracy} = (TP_1 + TP_2 + TP_3) / N$$

- 1 หาผลรวมของค่าบนเส้นทแยงมุมของ confusion matrix ( $TP_1, TP_2, TP_3$ )
- 2 หาผลรวมของค่าทั้งหมดใน confusion matrix (N)
- 3 นำผลรวมจากข้อ 1 หารด้วยผลรวมจากข้อ 2
- 4 แปลงเป็นร้อยละหรือเลขทศนิยมตามต้องการ

Accuracy วัดความถูกต้องโดยรวมของโมเดล แต่อาจไม่เหมาะกับข้อมูลที่ไม่สมดุล

## 🧮 ตัวอย่างการคำนวณ

	A	B	C
A	15	3	2
B	1	20	4
C	2	5	18

$$TP_A = 15$$

$$TP_B = 20$$

$$TP_C = 18$$

$$\text{ผลรวมที่ทำนายถูก} = 15 + 20 + 18 = 53$$

ผลรวมทั้งหมด =

$$15 + 3 + 2 + 1 + 20 + 4 + 2 + 5 + 18 = 70$$

$$\text{Accuracy} = 53 / 70 = 0.757$$

หรือ 75.7%

# การคำนวณ Precision สำหรับ 3 คลาส

# สูตรการคำนวณ Precision

## Σ สูตร Precision

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

- 1 สำหรับแต่ละคลาส หาค่า TP (True Positive) จากค่าบนเส้นทแยงมุม
- 2 หาค่า FP (False Positive) จากผลรวมของคอลัมน์ (ยกเว้นค่าบนเส้นทแยงมุม)
- 3 คำนวณ Precision สำหรับแต่ละคลาส:  $\text{Precision}_i = \text{TP}_i / (\text{TP}_i + \text{FP}_i)$
- 4 คำนวณค่าเฉลี่ยโดยใช้ Macro หรือ Micro averaging

## 🧮 ตัวอย่างการคำนวณ

คลาส A:  
 $\text{TP}_A = 15$   
 $\text{FP}_A = 1 + 2 = 3$   
 $\text{Precision}_A = 15 / (15 + 3) = 0.833$

	A	B	C
A	15	3	2
B	1	20	4
C	2	5	18

คลาส B:  
 $\text{TP}_B = 20$   
 $\text{FP}_B = 3 + 5 = 8$   
 $\text{Precision}_B = 20 / (20 + 8) = 0.714$

คลาส C:  
 $\text{TP}_C = 18$   
 $\text{FP}_C = 2 + 4 = 6$   
 $\text{Precision}_C = 18 / (18 + 6) = 0.750$

## ➡ วิธีการคำนวณค่าเฉลี่ย

### Macro Averaging

- คำนวณค่าเฉลี่ยของ Precision ทุกคลาส
- ให้น้ำหนักเท่ากันทุกคลาส
- เหมาะกับข้อมูลไม่สมดุล

### Micro Averaging

- รวม TP และ FP ของทุกคลาส
- คำนวณ Precision โดยรวม
- ได้รับอิทธิพลจากคลาสใหญ่

## Σ การคำนวณค่าเฉลี่ย

$$\text{Macro Precision} = (0.833 + 0.714 + 0.750) / 3 = 0.766$$
  
$$\text{Micro Precision} = (15 + 20 + 18) / (15+20+18 + 3+8+6) = 0.757$$

Precision วัดความแม่นยำของการทำนายคลาสบวก

# การคำนวณ Recall สำหรับ 3 คลาส



# สูตรการคำนวณ Recall

## Σ สูตร Recall

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

- 1 สำหรับแต่ละคลาส หาค่า TP (True Positive) จากค่าบนเส้นทแยงมุม
- 2 หาค่า FN (False Negative) จากผลรวมของแถว (ยกเว้นค่าบนเส้นทแยงมุม)
- 3 คำนวณ Recall สำหรับแต่ละคลาส:  $\text{Recall}_i = \text{TP}_i / (\text{TP}_i + \text{FN}_i)$
- 4 คำนวณค่าเฉลี่ยโดยใช้ Macro หรือ Micro averaging

## + ตัวอย่างการคำนวณ

คลาส A:  
 $\text{TP}_A = 15$   
 $\text{FN}_A = 3 + 2 = 5$   
 $\text{Recall}_A = 15 / (15 + 5) = 0.750$

	A	B	C
A	15	3	2
B	1	20	4
C	2	5	18

คลาส B:  
 $\text{TP}_B = 20$   
 $\text{FN}_B = 1 + 4 = 5$   
 $\text{Recall}_B = 20 / (20 + 5) = 0.800$

คลาส C:  
 $\text{TP}_C = 18$   
 $\text{FN}_C = 2 + 5 = 7$   
 $\text{Recall}_C = 18 / (18 + 7) = 0.720$

## ➔ วิธีการคำนวณค่าเฉลี่ย

### Macro Averaging

- คำนวณค่าเฉลี่ยของ Recall ทุกคลาส
- ให้น้ำหนักเท่ากันทุกคลาส
- เหมาะกับข้อมูลไม่สมดุล

### Micro Averaging

- รวม TP และ FN ของทุกคลาส
- คำนวณ Recall โดยรวม
- ได้รับอิทธิพลจากคลาสใหญ่

## Σ การคำนวณค่าเฉลี่ย

$$\text{Macro Recall} = (0.750 + 0.800 + 0.720) / 3 = 0.757$$

$$\text{Micro Recall} = (15 + 20 + 18) / (15+20+18 + 5+5+7) = 0.757$$

Recall วัดความสามารถในการตรวจจับคลาสบวกทั้งหมด

# การคำนวณ F1-score สำหรับ 3 คลาส

## สูตรการคำนวณ F1-score

### สูตร F1-score

$$F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

- 1 คำนวณ Precision สำหรับแต่ละคลาส
- 2 คำนวณ Recall สำหรับแต่ละคลาส
- 3 คำนวณ F1-score สำหรับแต่ละคลาส
- 4 คำนวณค่าเฉลี่ย (Macro/Micro/Weighted)

## ตัวอย่างการคำนวณ

### คลาส A


Precision = 0.833  
Recall = 0.750  
F1 = 0.789

### คลาส B

Precision = 0.714  
Recall = 0.800  
F1 = 0.755

### คลาส C

Precision = 0.750  
Recall = 0.720  
F1 = 0.735



## วิธีการคำนวณค่าเฉลี่ย

### Macro

- ค่าเฉลี่ยเท่ากันทุกคลาส
- เหมาะข้อมูลไม่สมดุล

### Micro

- รวม TP, FP, FN ทั้งหมด
- คำนวณโดยรวม

### Weighted

- ถ่วงน้ำหนักตามขนาดคลาส
- คลาสใหญ่มีน้ำหนักมากกว่า

## ผลลัพธ์การคำนวณค่าเฉลี่ย

### Macro F1

**0.760**

### Micro F1

**0.757**

### Weighted F1

**0.759**

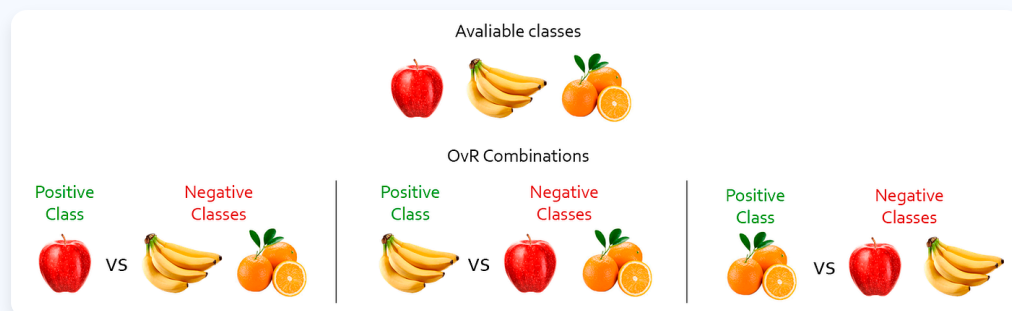
F1-score เป็นค่าเฉลี่ยเชิงฮาร์โมนิกของ Precision และ Recall

# การคำนวณ AUC/ROC สำหรับ 3 คลาส

## 1 One-vs-Rest (OvR)

เปรียบเทียบแต่ละคลาสกับคลาสอื่นๆ รวมกัน

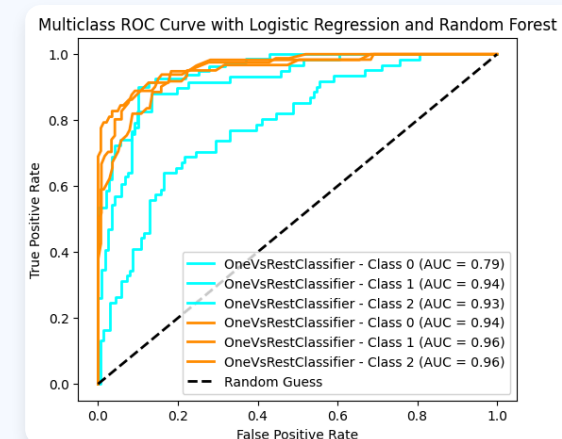
- ✓ กำหนด 1 คลาสเป็น Positive และคลาสที่เหลือเป็น Negative
- ✓ คำนวณ ROC AUC สำหรับแต่ละคลาส (3 ครั้งสำหรับ 3 คลาส)
- ✓ ค่าเฉลี่ย ROC AUC ทั้งหมดเป็นผลลัพธ์สุดท้าย



## 2 One-vs-One (OvO)

เปรียบเทียบคู่ของคลาสทุกคู่ที่เป็นไปได้

- ✓ สร้างคู่ของคลาสทั้งหมดที่เป็นไปได้ (6 คู่สำหรับ 3 คลาส)
- ✓ สำหรับแต่ละคู่ กำหนดคลาสแรกเป็น Positive และคลาสที่สองเป็น Negative
- ✓ คำนวณ ROC AUC สำหรับแต่ละคู่ แล้วหาค่าเฉลี่ย



ลักษณะ

OvR

OvO

จำนวนการคำนวณ

3 ครั้ง

6 ครั้ง

ความซับซ้อน

น้อยกว่า

มากกว่า

เหมาะกับ

ข้อมูลขนาดใหญ่

ข้อมูลขนาดเล็ก

$$\text{ค่าเฉลี่ย ROC AUC} = (AUC_1 + AUC_2 + \dots + AUC_n) / n$$

AUC/ROC วัดความสามารถในการแยกแยะคลาส ค่าใกล้ 1 แสดงถึงประสิทธิภาพสูง

# สรุปเมตริกการประเมินสำหรับ 3 คลาส



## Accuracy

$$(TP_1 + TP_2 + TP_3) / N$$

### 👍 ข้อดี

- เข้าใจง่าย
- คำนวณง่าย

### 🗨 ข้อเสีย

- ไม่เหมาะกับข้อมูลไม่สมดุล

### 🕒 เหมาะกับ

- ข้อมูลสมดุล
- การประเมินเบื้องต้น



## Precision

$$TP / (TP + FP)$$

### 👍 ข้อดี

- วัดความแม่นยำของการทำนาย
- เหมาะกับการลด False Positive

### 🗨 ข้อเสีย

- ไม่สนใจ False Negative

### 🕒 เหมาะกับ

- การวินิจฉัยโรค
- การตรวจจับสแปม



## Recall

$$TP / (TP + FN)$$

### 👍 ข้อดี

- วัดความสามารถในการตรวจจับ
- เหมาะกับการลด False Negative

### 🗨 ข้อเสีย

- ไม่สนใจ False Positive

### 🕒 เหมาะกับ

- การคัดกรองโรค
- การตรวจจับภัย



## F1-score

$$2 \times (Precision \times Recall) / (Precision + Recall)$$

### 👍 ข้อดี

- ค่าเฉลี่ยเชิงฮาร์โมนิก
- สมดุลระหว่าง Precision และ Recall

### 🗨 ข้อเสีย

- ไม่สามารถแยกค่า Precision และ Recall

### 🕒 เหมาะกับ

- ข้อมูลไม่สมดุล
- การเปรียบเทียบโมเดล



## AUC/ROC

พื้นที่ใต้เส้นโค้ง ROC

### 👍 ข้อดี

- ไม่ขึ้นกับ threshold
- วัดความสามารถในการแยกแยะ

### 🗨 ข้อเสีย

- คำนวณซับซ้อน
- ใช้เวลานาน

### 🕒 เหมาะกับ

- การเปรียบเทียบโมเดล
- การประเมินประสิทธิภาพโดยรวม



## แนวทางการเลือกใช้เมตริก

- ✓ ข้อมูลสมดุล: Accuracy, F1-score
- ✓ ข้อมูลไม่สมดุล: Precision, Recall, F1-score, Macro averaging
- ✓ ต้องการลด False Positive: Precision
- ✓ ต้องการลด False Negative: Recall
- ✓ การประเมินโดยรวม: AUC/ROC
- ✓ การเปรียบเทียบโมเดล: ใช้หลายเมตริคร่วมกัน